Biomedical Computer Vision - Final Project

Nicolò Zangheratti

1 Introduzione

Il progetto proposto chiedeva di partire da un dataset composto da immagini create al microscopio e contenenti 4 tipologie di cellule differenti (epiteliali, linfociti, macrofagi e neutrofili) e di applicare le conoscenze ottenute nel corso al fine di implementare una rete neurale che, fornitagli un'immagine del dataset, potesse segmentare e classificare le diverse cellule presenti in essa. Al fine di compiere ciò, sono giunto a sviluppare due metodologie differenti: dal momento che ho giudicato i risultati ottenuti equivalentemente corretti, ho ritenuto opportuno presentarli entrambi.
La prima strategia si basa su una segmentazione binaria dell'immagine seguita da una classificazione della maschera ottenuta.
La seconda, invece, esegue solamente una segmentazione multiclasse dell'immagine.

2 Segmentazione binaria e classificazione

2.1 Operazioni preliminari

Prima di proseguire, presento le operazioni preliminari che sono state necessarie

2.1.1 Risoluzione dei dataset issues

Invece di implementare le modifiche alle immagini durante il funzionamento del programma, ho ritenuto utile farlo antecedentemente in modo tale da avere un controllo diretto e più veloce dei risultati ottenuti.
Ho eseguito una normalizzazione delle immagini per omogeinizzare le loro intensità e un'equalizzazione per omogeneizzarne il contrasto.
Successivamente ho applicato un filtro Gaussiano poiché ho ritenuto possibile la presenza di rumore Gaussiano dato dall'acquisizione delle immagini stesse.
Infine, ho applicato un filtro mediano per contrastare rumore Poissoniano, possibilmente presente dato che le immagini sono state create al microscopio.

2.1.2 Maschere

Il dataset a cui dovevamo far riferimento era stato creato relativamente ad una challenge che poneva gli stessi obiettivi del progetto. Per la risoluzione, i ricercatori fornivano all'interno del dateset stesso delle annotazioni per ciascuna delle

immagini dalle quali, mediante codici rilasciati dai ricercatori stessi sul sito web della challenge, si potevano estrarre maschere binarie. Utilizzandolo, ho ottenuto una cartella contenente sottocartelle che si riferivano ad ogni singola immagine: in ognuna di esse, vi erano contenute 4 sotto-sottocartelle, una per tipologia di cellula.
Al fine di utilizzare questo materiale secondo la strategia pensata, ho ritenuto opportuno effettuare un overlay delle maschere, in modo tale da ottenere una segmentazione binaria di tutte le cellule presenti.

2.2 Segmentazione

Ho creato il dataframe associando ad ogni immagine del dataset la corrispondente maschera binaria ottenuta come precedentemente spiegato. Successivamente, si è suddiviso il dataframe nella sezione training e validation, tralasciando la parte di test date le dimensioni ridotte del dataset iniziale.
Il contenuto del dataframe ha poi subito trasformazioni, necessarie per l'apprendimento, tra cui il resize per poter risolvere un problema del dataset non precedentemente affrontato.
Successivamente, ho implementato la rete neurale U-Net e scelto come loss function BCEWithLogitsLoss, favorito per una segmentazione binaria e iniziato il training.
I risultati ottenuti sono discretamente accurati: il loro difetto principale è che falliscono talvolta nella distinzione tra parti dello sfondo e parti d'interesse

2.3 Classificazione

Ho creato il dataframe collezionando tutte le sottomaschere e associando ad ognuna il tipo di cellula che contengono. Ho deciso di operare così perché, una volta ottenuta la segmentazione binaria, potessi applicare su un suo risultato l'operazione di classificazione per comprendere quali tipologie di cellule fossero contenute nell'immagine originale.
Ho mappato le classi nel modo seguente (importante per la comprensione dei risultati): Epithelial: 0, Lymphocyte: 1, Macrophage: 2, Neutrophil: 3.
Ho poi implementato la rete neurale di PyTorch ResNet18 con i pesi associati e posto come criterion CrossEntropyLoss per poter eseguire una classificazione multiclasse. Infine, ho fatto partire il training.

2.4 Risultato

Per la visualizzazione del risultato, seleziono casualmente un'immagine del dataset iniziale e vi applico il modello allenato per la segmentazione, ottenendone una segmentazione binaria. Successivamente, carico la segmentazione nel modello per la classificazione e stampo le probabilità associate ad ogni classe.

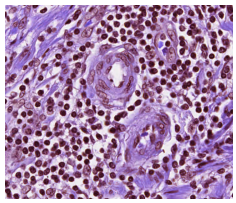


Figure 1: Immagine originale

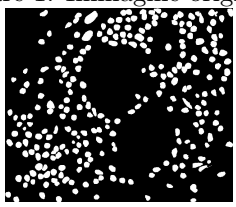


Figure 2: Maschera originale

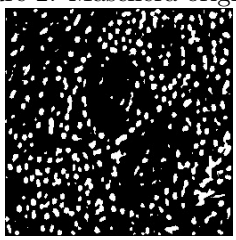


Figure 3: Maschera predetta

La classificazione restituisce invece:

$$[0.9994 \quad 0.9992 \quad 0.0000 \quad 0.0000]$$

Sfruttando un altro codice fornito sempre dai creatori della challenge che permette di conoscere il numero esatto di cellule presenti, arriviamo a conoscere che nell'immagine data vi sono 2 cellule epiteliali e 253 linfociti. Si può dunque concludere che la classificazione è stata corretta.

3 Segmentazione multiclasse

3.1 Operazioni preliminari

3.1.1 Risoluzione dei dataset issues

Svolto in modo identico a come descritto precedentemente.

3.1.2 Maschere

Una volta ottenute le maschere tramite gli strumenti forniti dai creatori della challenge, ho eseguito un overlay ma stavolta non binario: ad ogni classe è stato associato un valore differente (0: background, 1: epiteliali, 2: linfociti, 3: macrofagi, 4: neutrofili) e ad ogni pixel si è attribuito il valore corrispondente.

3.2 Segmentazione multiclasse

Si è creato il dataframe associando ad ogni immagine la sua maschera multiclasse corrispondente. Ho implementato la rete neurale U-Net e scelto come loss function CrossEntropyLoss, favorito per una segmentazione multiclasse. Nel train loop ho scelto di utilizzare lo f1 score in modalità 'weighted'. Infine ho fatto partire il training con un numero di epoch maggiore a prima dato che, con questa strategia, di fatto vengono compiuti i due passaggi precedenti in uno solo.

3.3 Risultato

I risultati ottenuti e mostrati nel notebook sono discretamente corretti anche se mostrano diverse debolezze: vengono incluse parti dello sfondo; le cellule correttamente segmentate talvolta vengono classificate erroneamente.

4 Tentativi

Le scelte sopra descritte non corrispondono alla strada imboccata all'inizio del progetto ma seguono da un tentativo di miglioramento dei risultati originariamente ottenuti.
Inizialmente, consideravo la diversa distribuzione dei vari tipi di cellule all'interno del dataset come un possibile ostacolo. Avevo quindi passato alle loss functions della classificazione per la prima strategia e della segmentazione per la seconda dei pesi, calcolati come segue:
per ogni immagine contenuta nei rispettivi dataframe, si contavano i pixel occupati da ciascuna classe e applicavo la seguente formula:

$$w_i = \frac{sum}{npixel_i} \tag{1}$$

dove $npixel_i$ è il numero di pixel occupato dalla i-esima classe nel dataset e $sum = \sum_i npixel_i$. Tuttavia, i risultati ottenuti con queste modifiche risultavano peggiori, sia visibilmente che numericamente secondo lo f1 score. Sono quindi giunto alla conclusione che il dataset non fosse effettivamente sbilanciato o che lo sia ma le strategie da me perseguite siano insufficienti.